Big Data
大數據理論及實務應用

Created by 孫善堂 【小孫學堂】

Requests Methods
Get or Post?

Created by 孫善堂 【小孫學堂】

What is the BeautifulSoup ?

1.網頁爬蟲工具庫

2.自動轉換為utf-8編碼


相關連結
採購統計
行政法人 相關採購資訊
加值服務 訂閱
優先採購
「購買原住民及身心障礙者所提供之產品或勞務」採購專區平台
法人團體 帳號申請
安裝程式 環境檢測
檢索設定
同音
容錯
查詢
項次 種類 機關名稱 標案案號 標案名稱 招標公告日期
1 招標公告 臺南市體育處 TNS109-05 109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案 109/07/17
2 招標公告 國防部空軍司令部 EI10002P003 投影系統維護案 109/07/17
3 招標公告 財團法人國際合作發展基金會 ICDF-109-024 110年度國際人力資源培訓研習班計畫會議服務 109/07/17
4 招標公告 台灣電力股份有限公司通霄發電廠 3700900073 109年度#1機氣渦輪機輔機大修工作 109/07/17
FI1080601CM 花蓮縣消防

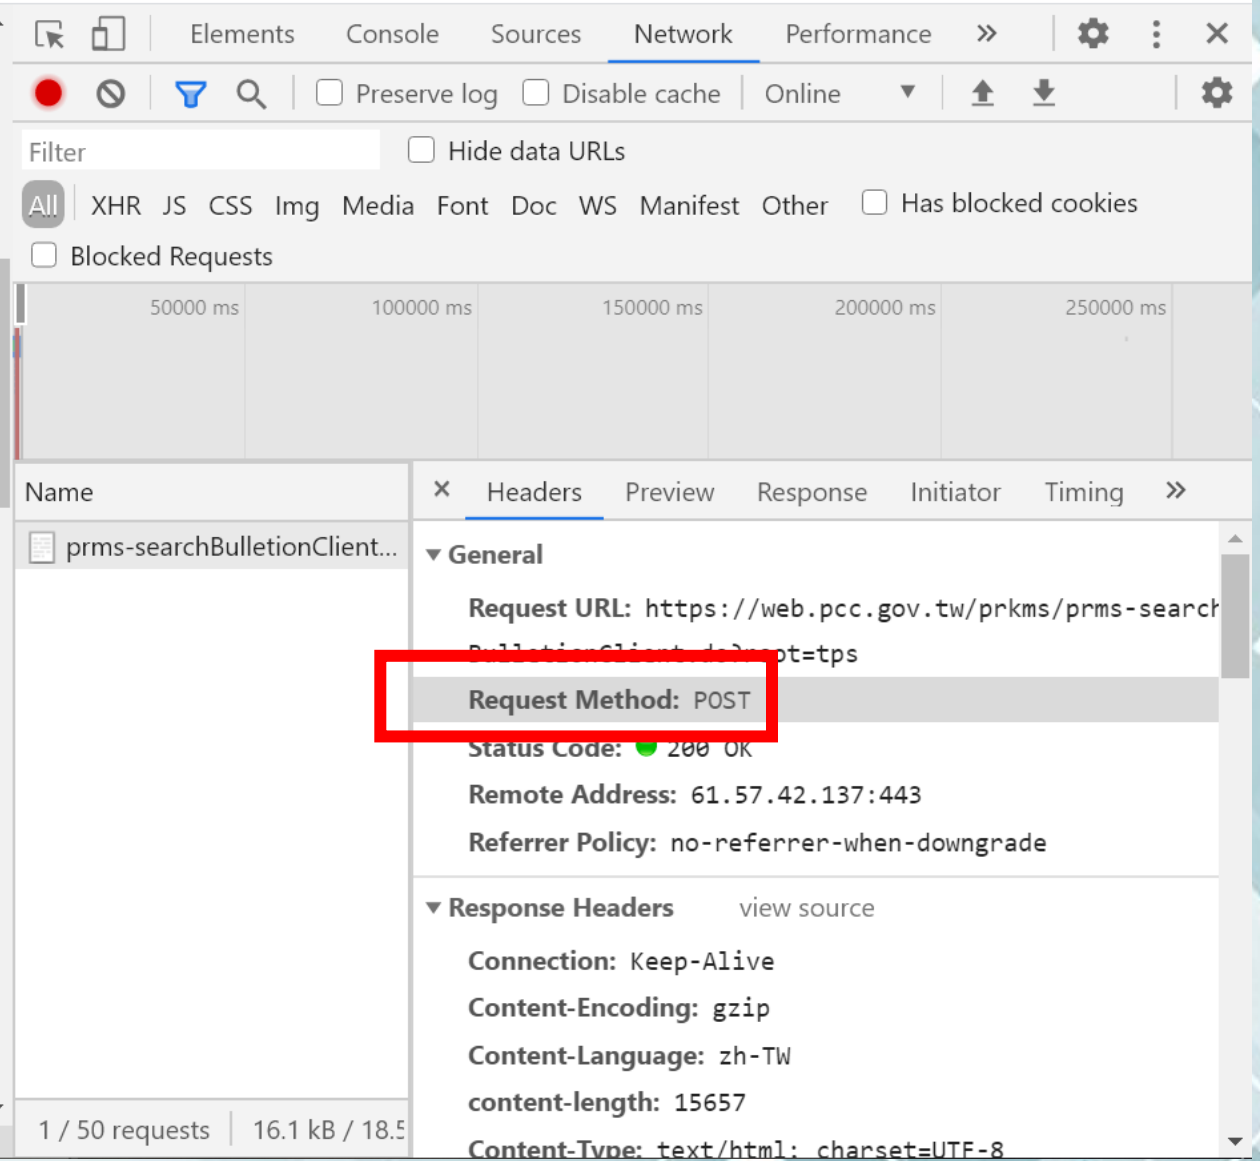
Elements
Console
Sources
Network
Performance
Preserve log
Disable cache
Online
Filter
Hide data URLs
All
XHR
JS
CSS
Img
Media
Font
Doc
WS
Manifest
Other
Has blocked cookies
Blocked Requests
50000 ms
100000 ms
150000 ms
200000 ms
250000 ms
Name
prms-searchBulletionClient...
1 / 50 requests
16.1 kB / 18.5
Headers
Preview
Response
Initiator
Timing
General
Request URL: https://web.pcc.gov.tw/prkms/prms-search
Request Method: POST
Status Code: 200 OK
Remote Address: 61.57.42.137:443
Referrer Policy: no-referrer-when-downgrade
Response Headers
view source
Connection: Keep-Alive
Content-Encoding: gzip
Content-Language: zh-TW
content-length: 15657
Content-Type: text/html; charset=UTF-8

標籤GET(明信片)

http-header

使用 GET 的時候我們直接將要傳送的資料以 Query String（一種Key/Vaule的編碼方式）加在我們要寄送的地址(URL)後面，然後交給郵差傳送。

POST(信封與信件)

message-body

http-header

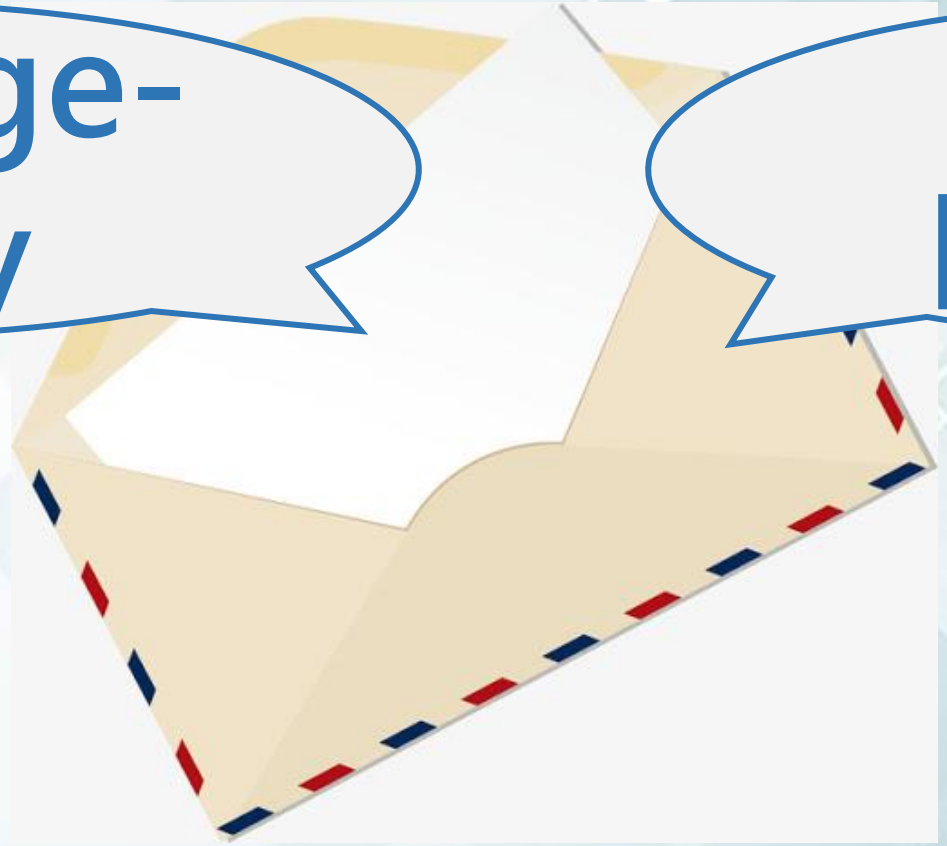

使用 POST 的時候則是將寄送地址(URL)寫在信封上，另外將要傳送的資料寫在另一張信紙後，將信紙放到信封裡面，交給郵差傳送。

Form Data

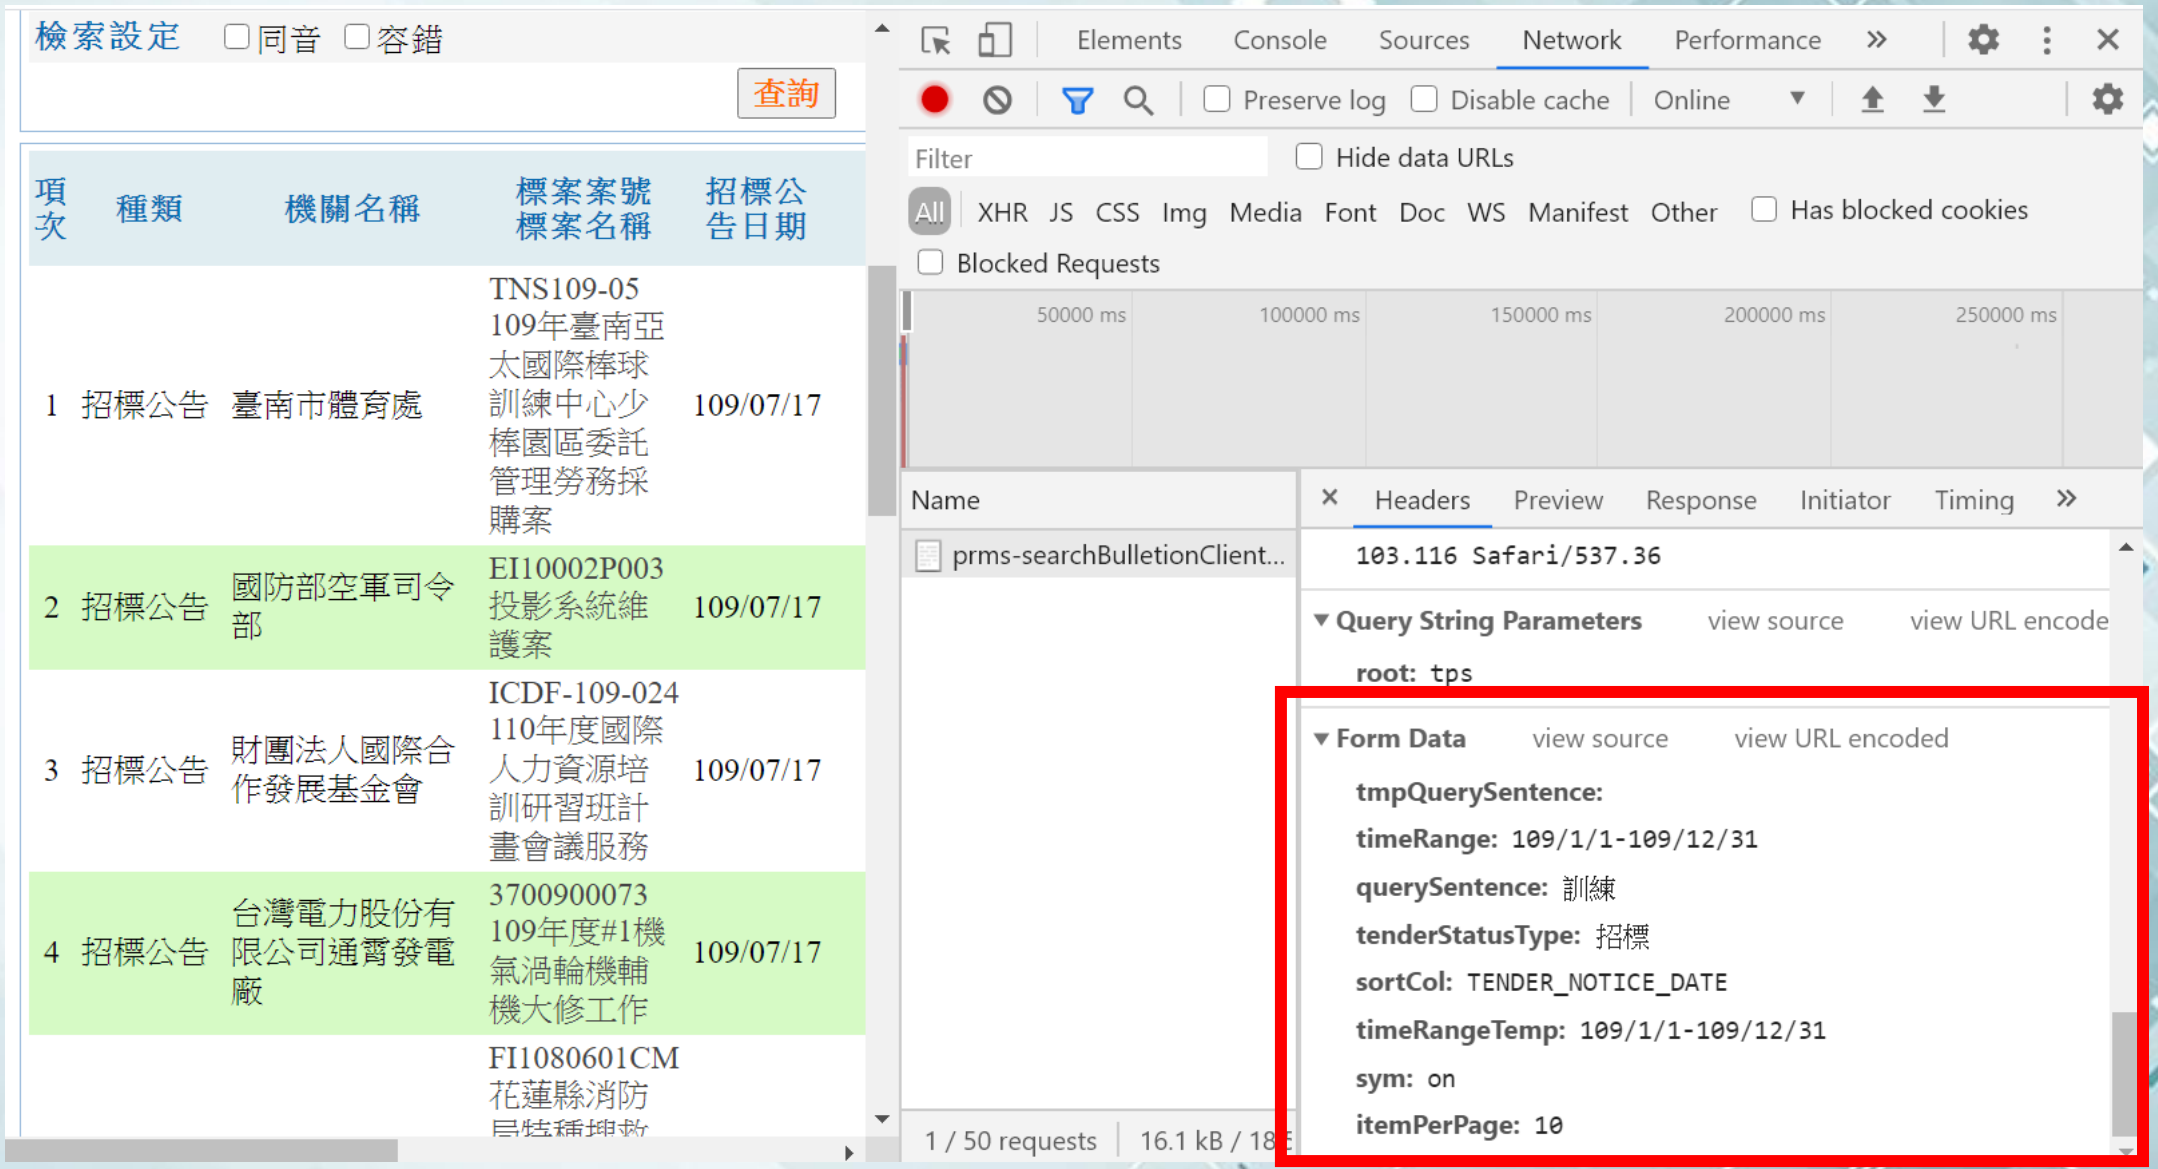
檢索設定
同音
容錯
查詢
項次
種類
機關名稱
標案案號
標案名稱
招標公告日期
1 招標公告 臺南市體育處 TNS109-05 109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案 109/07/17
2 招標公告 國防部空軍司令部 EI10002P003 投影系統維護案 109/07/17
3 招標公告 財團法人國際合作發展基金會 ICDF-109-024 110年度國際人力資源培訓研習班計畫會議服務 109/07/17
4 招標公告 台灣電力股份有限公司通霄發電廠 3700900073 109年度#1機氣渦輪機輔機大修工作 109/07/17
FI1080601CM 花蓮縣消防
Elements
Console
Sources
Network
Performance
Preserve log
Disable cache
Online
Filter
Hide data URLs
All
XHR
JS
CSS
Img
Media
Font
Doc
WS
Manifest
Other
Has blocked cookies
Blocked Requests
50000 ms
100000 ms
150000 ms
200000 ms
250000 ms
Name
prms-searchBulletionClient...
Headers
Preview
Response
Initiator
Timing
103.116 Safari/537.36
Query String Parameters
view source
view URL encode
root: tps
Form Data
view source
view URL encoded
tmpQuerySentence:
timeRange: 109/1/1-109/12/31
querySentence: 訓練
tenderStatusType: 招標
sortCol: TENDER_NOTICE_DATE
timeRangeTemp: 109/1/1-109/12/31
sym: on
itemPerPage: 10
1 / 50 requests
16.1 kB / 18

使用POST抓取資料

Requests.post(URL,DATA)

```
url = 'https://web.pcc.gov.tw/prkms/prms-searchBulletionClient.do?root=tps'

data = {'tmpQuerySentence': None,
'timeRange':'109/1/1-109/12/31',
'querySentence':'訓練',
'tenderStatusType':'招標',
'sortCol':'TENDER_NOTICE_DATE',
'timeRangeTemp':'109/1/1-109/12/31',
'sym':'on',
'itemPerPage':'100'}

res = requests.post(url,data)
soup = BeautifulSoup(res.text)
```

DATA以dictionary形式讀入

網路爬蟲實作
政府電子採購招標清單

Created by 孫善堂 【小孫學堂】

requests method 分布

GET

POST

html階層觀察與物件抓取

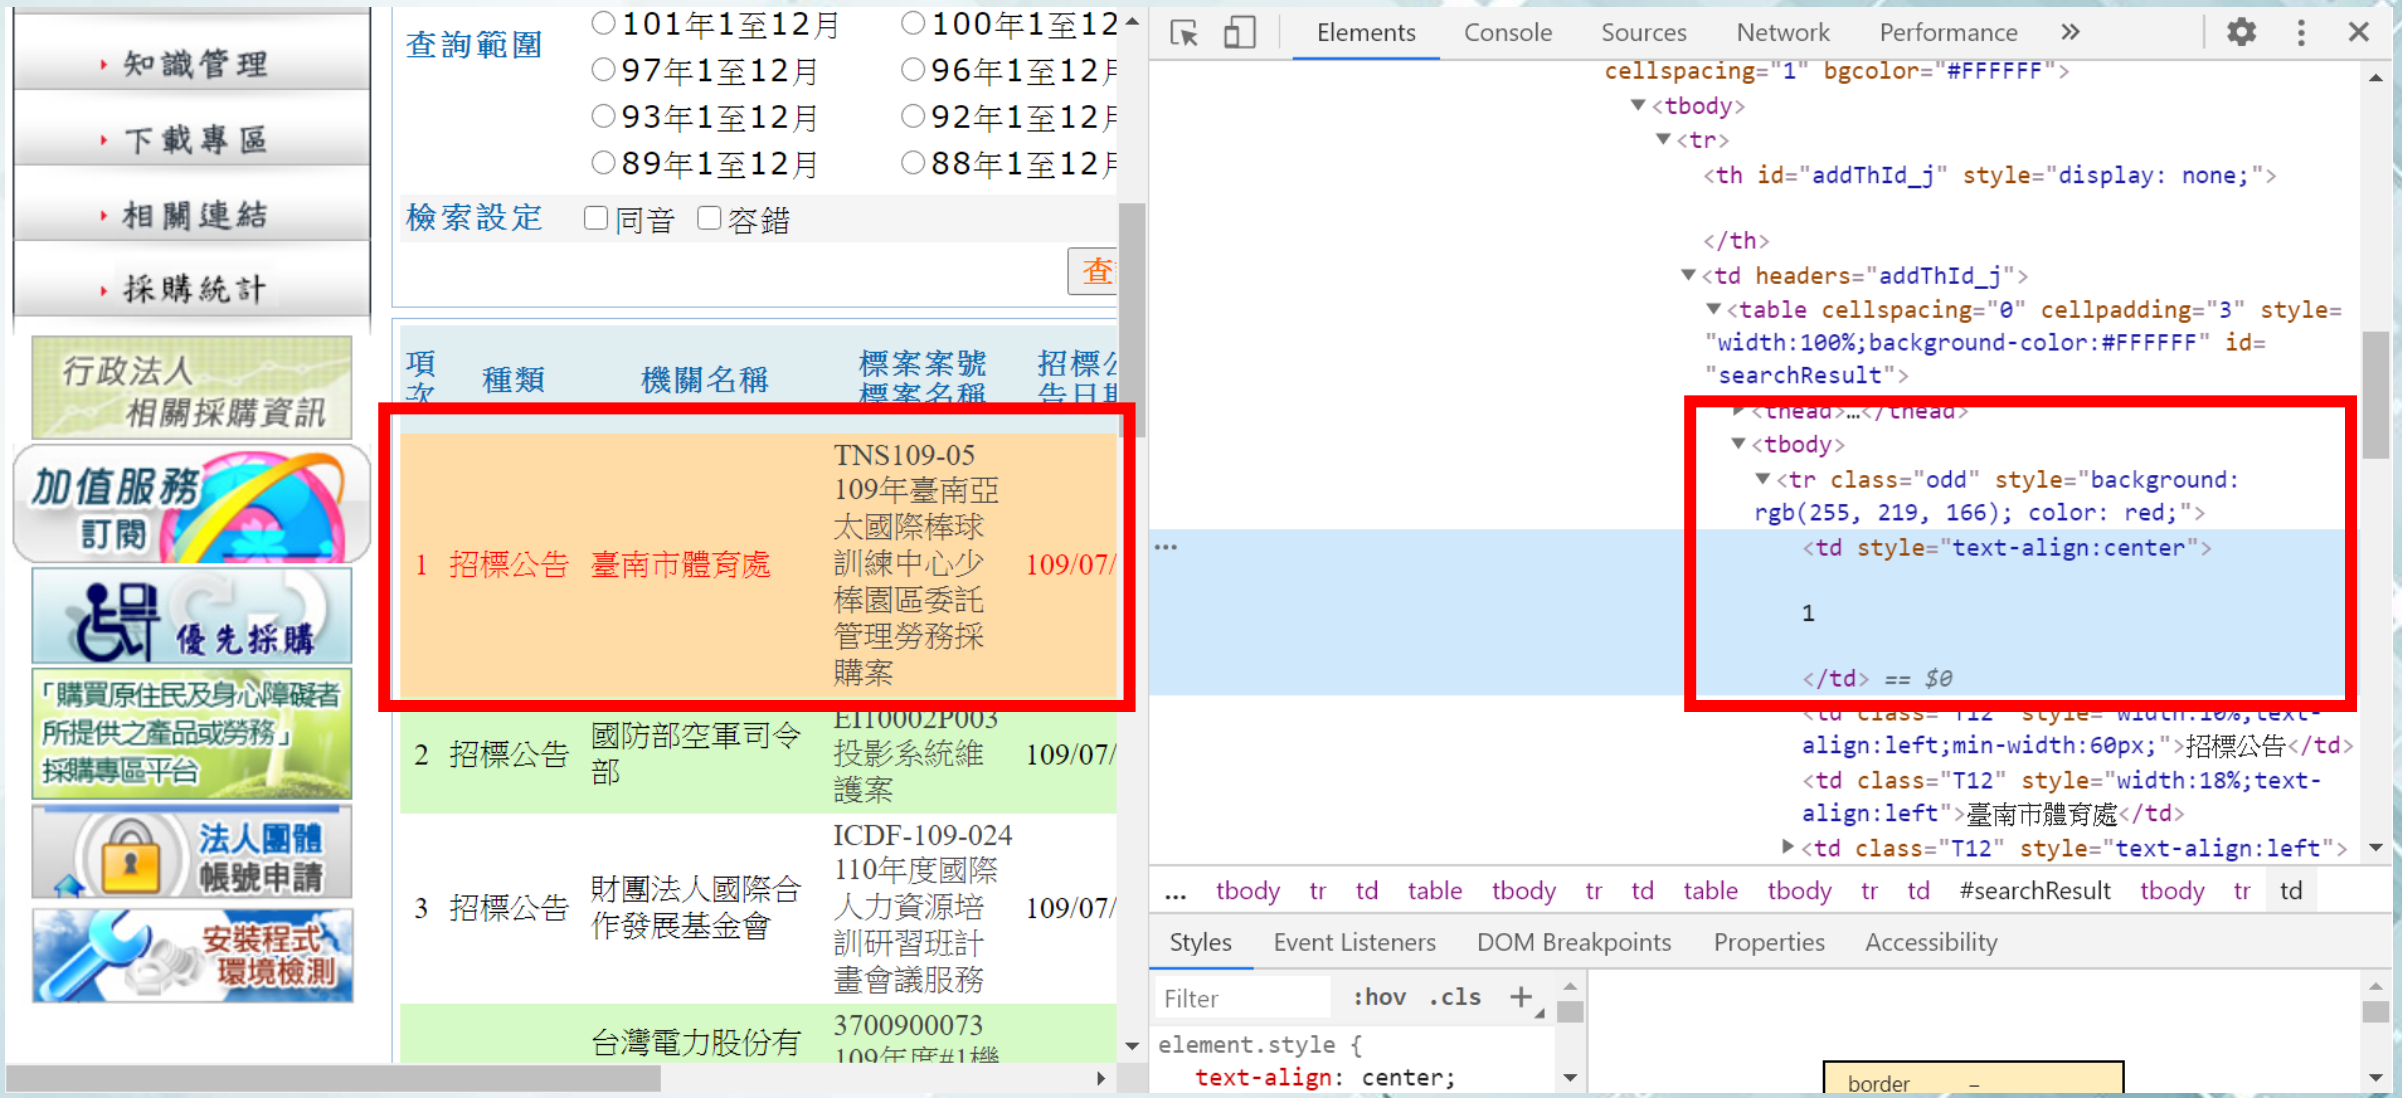

html階層觀察與物件抓取

```
'tenderStatusType':'招標',
'sortCol':'TENDER_NOTICE_DATE',
'timeRangeTemp':'109/1/1-109/12/31',
'sym':'on',
'itemPerPage':'100'}

res = requests.post(url,data)
soup = BeautifulSoup(res.text)

print(soup.select('tbody')[0].select('tr')[0].select('td')[3].a.div.string)
```

```
109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案
```

以for迴圈針對各標案

```
for case in soup.select('tbody')[0].select('tr'):
    print(case.select('td')[3].a.div.string)
```

109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案
投影系統維護案
110年度國際人力資源培訓研習班計畫會議服務
109年度#1機氣渦輪機輔機大修工作
花蓮縣消防局特種搜救隊訓練基地建置新建統包工程
運動地墊及拳擊訓練擂台採購案
109年度新建餐廳3樓休閒中心購置遊戲機1批案
檢驗科設備、藥劑科設備、病理科設備、轉譯中心設備、護理科設備及氣體設備等10項
超音波焊接(熱熔)機組乙項
臺中市西屯區協和國民小學幼兒園搬遷修繕工程委託技術服務勞務採購

找到其他資料欄位

```
print(soup.select('tbody')[0].select('tr')[0].select('td')[2].string)
print(soup.select('tbody')[0].select('tr')[0].select('td')[3].a.div.string)
print(soup.select('tbody')[0].select('tr')[0].select('td')[6].string)
print('https://web.pcc.gov.tw'+soup.select('tbody')[0].select('tr')[0].select('a')[0]['href'])
```

```
臺南市體育處
109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案
109/07/27
https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=common&scope=F&primaryKey=53204344
```

製作excel報表

```
wb = openpyxl.Workbook()

ws = wb.active

ws['A1'] = '招標機關'
ws['B1'] = '標案名稱'
ws['C1'] = '截止投標'
ws['D1'] = '標案種類'
ws['E1'] = '預算金額'
ws['F1'] = '網址'
ws['I1'] = '聯絡人'
ws['G1'] = '連絡電話'



wb.save('招標清單'+str(datetime.date.today())+'.xlsx')

print('報表製作完成')
```

填入excel欄位

```
ws['E1'] = '預算金額'
ws['F1'] = '網址'
ws['I1'] = '聯絡人'
ws['G1'] = '連絡電話'

for item in soup.select('tbody')[0].select('tr'):
    ws.append([item.select('td')[2].string,\
               item.select('td')[3].a.div.string,\
               item.select('td')[6].string,\
               '',\
               '',\
               'https://web.pcc.gov.tw'+item.select('a')[0]['href'],\
               '',\
               ''])

wb.save('招標清單'+str(datetime.date.today())+'.xlsx')

print('報表製作完成')
```

報表製作完成

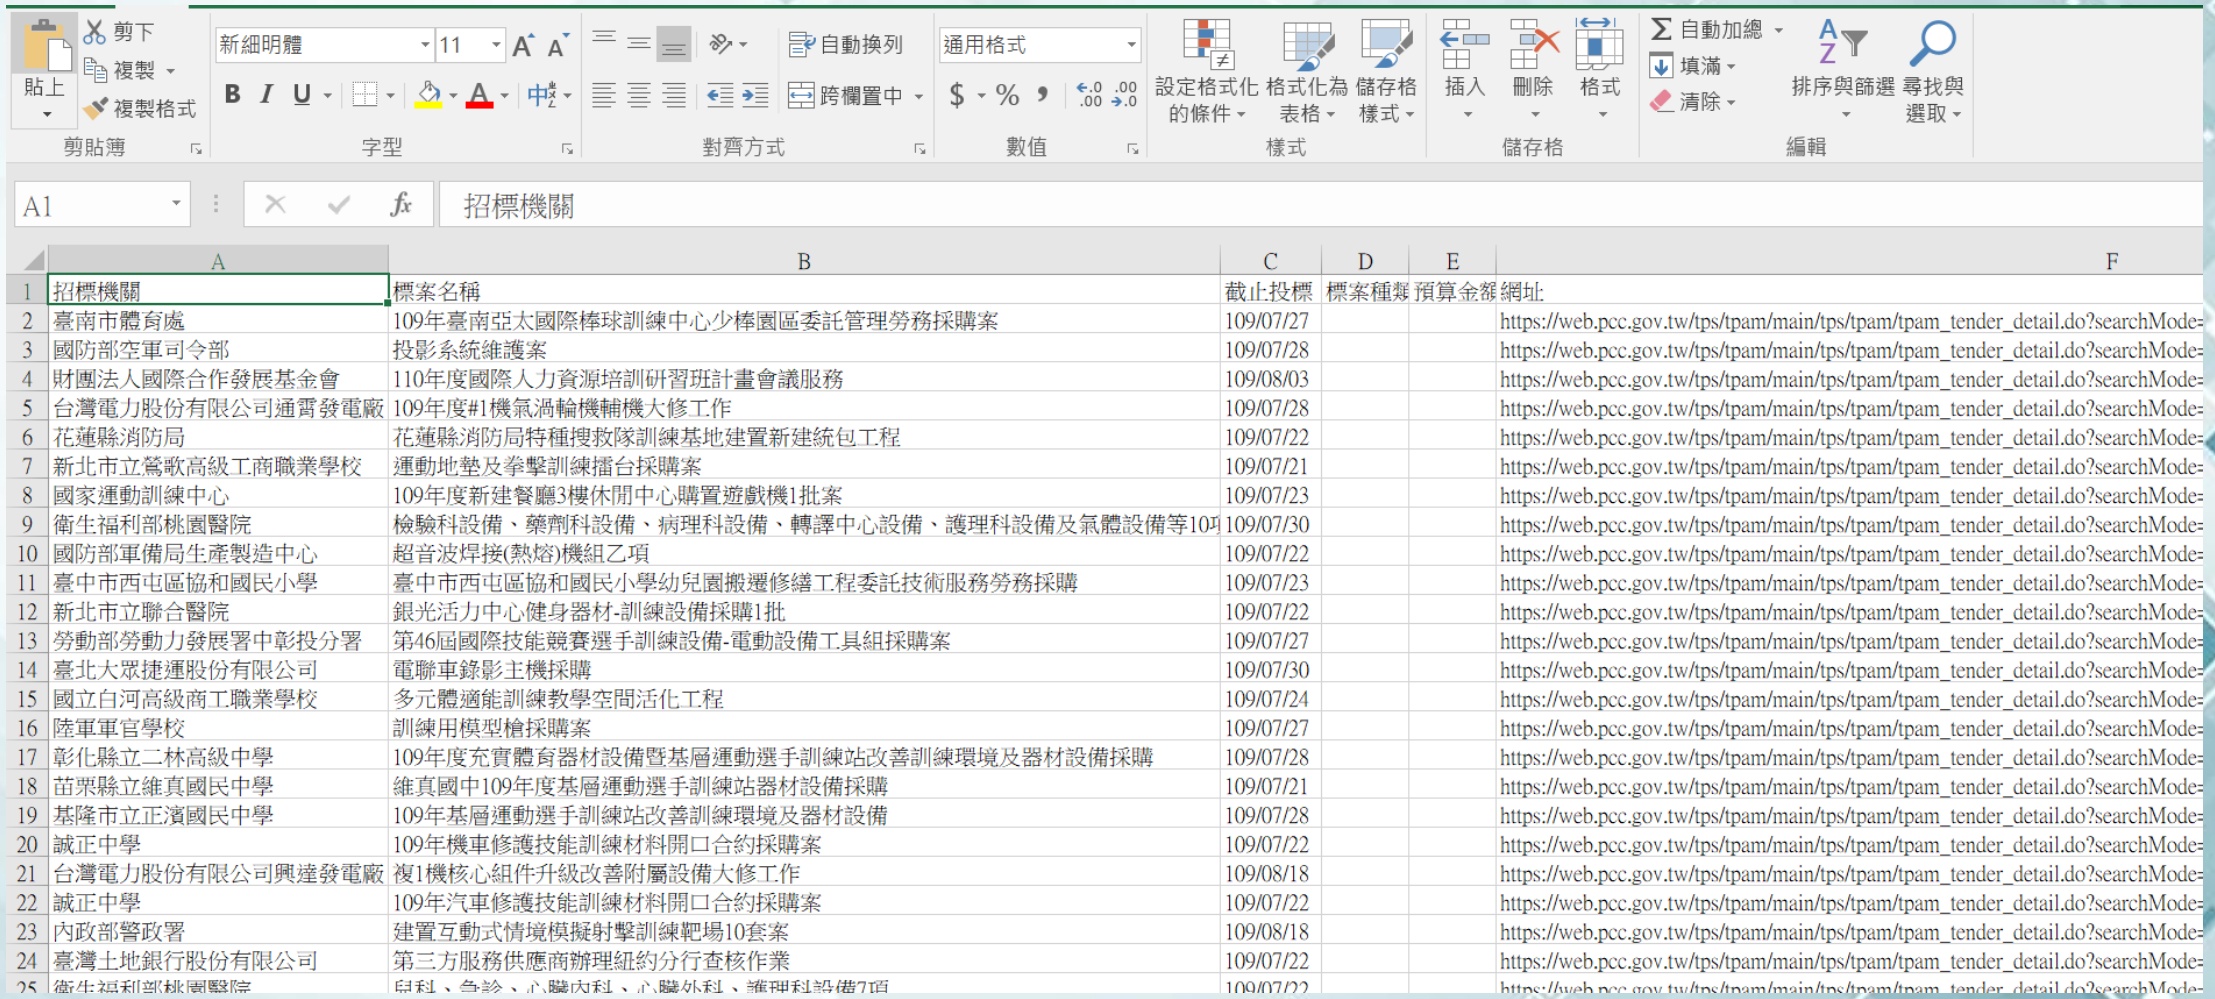

	A	B	C	D	E	F
1	招標機關	標案名稱	截止投標	標案種類	預算金額	網址
2	臺南市體育處	109年臺南亞太國際棒球訓練中心少棒園區委託管理勞務採購案	109/07/27			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
3	國防部空軍司令部	投影系統維護案	109/07/28			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
4	財團法人國際合作發展基金會	110年度國際人力資源培訓研習班計畫會議服務	109/08/03			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
5	台灣電力股份有限公司通霄發電廠	109年度#1機氣渦輪機輔機大修工作	109/07/28			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
6	花蓮縣消防局	花蓮縣消防局特種搜救隊訓練基地建置新建統包工程	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
7	新北市立鶯歌高級工商職業學校	運動地墊及拳擊訓練擂台採購案	109/07/21			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
8	國家運動訓練中心	109年度新建餐廳3樓休閒中心購置遊戲機1批案	109/07/23			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
9	衛生福利部桃園醫院	檢驗科設備、藥劑科設備、病理科設備、轉譯中心設備、護理科設備及氣體設備等10項	109/07/30			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
10	國防部軍備局生產製造中心	超音波焊接(熱熔)機組乙項	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
11	臺中市西屯區協和國民小學	臺中市西屯區協和國民小學幼兒園搬遷修繕工程委託技術服務勞務採購	109/07/23			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
12	新北市立聯合醫院	銀光活力中心健身器材-訓練設備採購1批	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
13	勞動部勞動力發展署中彰投分署	第46屆國際技能競賽選手訓練設備-電動設備工具組採購案	109/07/27			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
14	臺北大眾捷運股份有限公司	電聯車錄影主機採購	109/07/30			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
15	國立白河高級商工職業學校	多元體適能訓練教學空間活化工程	109/07/24			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
16	陸軍軍官學校	訓練用模型槍採購案	109/07/27			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
17	彰化縣立二林高級中學	109年度充實體育器材設備暨基層運動選手訓練站改善訓練環境及器材設備採購	109/07/28			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
18	苗栗縣立維真國民中學	維真國中109年度基層運動選手訓練站器材設備採購	109/07/21			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
19	基隆市立正濱國民中學	109年基層運動選手訓練站改善訓練環境及器材設備	109/07/28			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
20	誠正中學	109年機車修護技能訓練材料開口合約採購案	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
21	台灣電力股份有限公司興達發電廠	複1機核心組件升級改善附屬設備大修工作	109/08/18			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
22	誠正中學	109年汽車修護技能訓練材料開口合約採購案	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
23	內政部警政署	建置互動式情境模擬射擊訓練靶場10套案	109/08/18			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
24	臺灣土地銀行股份有限公司	第三方服務供應商辦理紐約分行查核作業	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=
25	衛生福利部桃園醫院	兒科、急診、心臟內科、心臟外科、護理科設備7項	109/07/22			https://web.pcc.gov.tw/tps/tpam/main/tps/tpam/tpam_tender_detail.do?searchMode=

二層爬蟲架構

```
for item in soup.select('tbody')[0].select('tr'):
    res2 = requests.get('https://web.pcc.gov.tw'+item.select('a')[0]['href'])
    soup2 = BeautifulSoup(res2.text)
    ws.append([item.select('td')[2].string,\
               item.select('td')[3].a.div.string,\
               item.select('td')[6].string,\
               '',\
               soup2.select('table')[0].select('tr')[57].td.text,\
               'https://web.pcc.gov.tw'+item.select('a')[0]['href'],\
               '',\
               ''])
    delay = random.randint(10,20)
    print('已抓取一筆資料，等待'+str(delay)+'秒')
    time.sleep(delay)
```

二層爬蟲去除多餘字元

```
print(soup2.select('table')[0].select('tr')[i].td.text.replace('\t','').replace('\n','').replace('\r',''))
```

常見多餘字元	
\t	**TAB**
\n	空行
\r	回車
	半形、全形空白

二層爬蟲判斷架構

```
res2 = requests.get('https://web.pcc.gov.tw'+soup.select('tbody')[0].select('tr')[3].select('td')[3].a['href'])
soup2 = BeautifulSoup(res2.text)
i=40
while i<60:
    i+=1
    if soup2.select('table')[0].select('tr')[i].th.text.replace('\t','').replace('\n','').replace('\r','') == '聯絡人':
        print(soup2.select('table')[0].select('tr')[i].td.text.replace('\t','').replace('\n','').replace('\r',''))
    if soup2.select('table')[0].select('tr')[i].th.text.replace('\t','').replace('\n','').replace('\r','') == '聯絡電話':
        print(soup2.select('table')[0].select('tr')[i].td.text.replace('\t','').replace('\n','').replace('\r',''))
    if soup2.select('table')[0].select('tr')[i].th.text.replace('\t','').replace('\n','').replace('\r','') == '預算金額':
        print(soup2.select('table')[0].select('tr')[i].td.text.replace('\t','').replace('\n','').replace('\r',''))
```

加time.sleep控制流量！

```
for item in soup.select('tbody')[0].select('tr'):
    res2 = requests.get('https://web.pcc.gov.tw'+item.select('a')[0]['href'])
    soup2 = BeautifulSoup(res2.text)
    ws.append([item.select('td')[2].string,\
               item.select('td')[3].a.div.string,\
               item.select('td')[6].string,\
               '',\
               soup2.select('table')[0].select('tr')[57].td.text,\
               'https://web.pcc.gov.tw'+item.select('a')[0]['href'],\
               '',\
               ''])
    delay = random.randint(10,20)
    print('已抓取一筆資料，等待'+str(delay)+'秒')
    time.sleep(delay)
```

抓取過快則需手動驗證

```
---------------------------------------------------------------------------
IndexError                                Traceback (most recent call last)
<ipython-input-7-224f217611c4> in <module>
     41                     item.select('td')[6].string,\
     42                     '',\
---> 43                     soup2.select('table')[0].select('tr')[57].td.text,\
     44                     'https://web.pcc.gov.tw'+item.select('a')[0]['href'],\
     45                     '',\

IndexError: list index out of range
```